

BigQuery 서버리스 분석 실습 개요

BigQuery는 구글이 제공하는 완전관리형 서버리스 데이터 웨어하우스입니다. 사용자는 인프라나 성능 튜닝 대신 SQL 쿼리로 데이터 분석에 집중할 수 있습니다 ¹. 즉, **서버나 클러스터를 직접 관리할 필요 없이** 필요한 만큼 자동으로 확장되는 분석 환경을 제공하여, 스타트업에서도 복잡한 설정 없이 대규모 데이터를 다룰 수 있습니다. BigQuery는 스토리지와 컴퓨팅을 분리하여 운영하며 ¹, Cloud Storage, Bigtable 등 다양한 외부 데이터 소스와 연계하여 데이터를 조회할 수 있습니다.

BigQuery의 **외부 테이블(external table)** 기능을 사용하면, CSV 파일을 BigQuery 내부로 로드하지 않고도 Cloud Storage에 저장된 데이터를 바로 쿼릴 수 있습니다. 즉, 데이터를 복제할 필요 없이 외부에 있는 데이터를 읽기 전용으로 연결하여 분석할 수 있습니다 ² ³. 이 실습에서는 GCP의 Cloud Storage에 업로드한 공공 CSV 파일을 BigQuery 외부 테이블로 생성한 뒤, SQL 집계 쿼리를 실행해보며 서버리스 분석 개념을 익힙니다.

데이터셋 소개

이 실습에서는 NASA 공개 데이터인 **Meteorite Landings** 데이터셋을 사용합니다. 이 데이터셋은 지구에 떨어진(또는 발견된) 운석 34,513건의 정보를 포함하며 ⁴, 각 레코드에는 운석의 위치(`place`), 종류(`type_of_meteorite`), 무게(`mass_g`), 낙하/발견 여부(`fell_found`), 연도(`year`), 위치 좌표(`latitude`, `longitude`) 등의 필드가 들어 있습니다 ⁴. 예를 들어, `mass_g`는 운석의 질량(그램)을 나타내며, `fell_found` 컬럼은 운석이 우주에서 떨어진 경우('Fell')와 지상에서 발견된 경우('Found')를 구분합니다. **주요 컬럼 예시:**

- `place` - 운석 발견 위치(지명)
- `mass_g` - 운석의 질량(그램 단위)
- `year` - 운석이 지구에 떨어지거나 발견된 연도
- `fell_found` - 운석의 **떨어짐(Fell)** 또는 **발견(Found)** 여부

이 데이터를 이용해 전체 건수, 연도별 분포, 무게 통계 등을 구해보며 BigQuery SQL 분석을 연습할 수 있습니다.

실습 절차

1. **Cloud Storage에 데이터 업로드**
2. **콘솔(GCP Console):** Cloud Storage 화면으로 이동하여 새 버킷을 생성합니다(버킷 이름은 프로젝트 내에서 고유해야 함). 버킷 지역(Region)은 BigQuery 데이터셋과 동일하게 설정합니다. 생성된 버킷을 클릭하고 **파일 업로드** 버튼을 눌러 NASA 데이터셋 CSV(`Meteorite_Landings.csv`)를 업로드합니다.
3. **클라우드 CLI (gsutil):** 로컬 컴퓨터나 Cloud Shell에서 다음과 같이 명령어를 입력합니다. 먼저 버킷을 만듭니다(`my-bucket`은 원하는 이름으로 변경).

```
gsutil mb -p [PROJECT_ID] -c STANDARD -l us-central1 gs://my-bucket
```

이어서 NASA CSV 파일을 다운로드한 후, 다음 명령으로 버킷에 복사합니다.

```
# 예시: wget을 이용해 CSV 파일 다운로드
wget https://data.nasa.gov/docs/legacy/meteorite_landings/
Meteorite_Landings.csv
gsutil cp Meteorite_Landings.csv gs://my-bucket/
```

(CSV 파일은 [NASA 오픈데이터](#)에서 받을 수 있습니다.)

4. BigQuery 데이터셋 생성

BigQuery에서 모든 테이블은 **데이터셋(dataset)** 아래에 생성됩니다. 데이터셋은 테이블과 뷰의 최상위 컨테이너로 사용됩니다 ⁵.

5. **콘솔:** BigQuery 페이지로 이동하여 왼쪽 탐색기에서 프로젝트를 확장하고 **데이터셋 만들기**를 클릭합니다. 데이터셋 식별자를 입력(예: `meteorite_dataset`)하고 데이터 보관 위치(Region)를 선택합니다. 저장 후 새 데이터셋이 생성됩니다.

6. **클라우드 CLI (bq):** 다음과 같이 `bq mk` 명령어로 데이터셋을 생성합니다.

```
bq mk --dataset --description "Meteorite data" --location=US
[PROJECT_ID]:meteorite_dataset
```

`--location`은 버킷의 위치(위 예시에서는 `us-central1` 또는 `US` 다중 리전)를 맞춰야 합니다.

7. 외부 테이블 생성

업로드한 CSV 파일을 참조하는 외부 테이블을 만듭니다.

8. **콘솔:** BigQuery UI에서 왼쪽 탐색기에서 생성한 데이터셋(`meteorite_dataset`)을 선택한 뒤, 상단의 **테이블 만들기(Create table)** 버튼을 클릭합니다.

- 소스(Source):** `Create table from`에서 **Google Cloud Storage**를 선택하고, `Select file from GCS bucket`에 방금 업로드한 파일 경로(`gs://my-bucket/Meteorite_Landings.csv`)를 입력합니다. 파일 형식은 **CSV**를 선택합니다.
- 대상(Destination):** 프로젝트와 데이터셋을 확인한 뒤, **테이블 이름**(예: `meteorites_ext`)을 입력하고, **테이블 유형(Table type)**을 **External table**로 설정합니다 ⁶.
- 스키마(Schema):** 스키마를 수동으로 지정하거나 **자동 감지(Auto detect)** 기능을 활성화합니다 ⁷. (자동 감지는 CSV 파일에서 컬럼을 추정하여 설정해줍니다.)
- 생성(Create)**을 클릭하면 외부 테이블이 만들어집니다.

9. **클라우드 CLI (bq):** `bq mk` 명령어와 `--external_table_definition` 플래그를 사용하여 외부 테이블을 생성합니다. 예를 들어, 주요 컬럼만 정의한다면:

```
bq mk --external_table_definition=\
meteorites_ext::place:STRING,type_of_meteorite:STRING,mass_g:FLOAT,year:STRING,fell_found
my-bucket/Meteorite_Landings.csv \
[PROJECT_ID]:meteorite_dataset.meteorites_ext
```

여기서 `meteorites_ext`는 테이블 이름, `@CSV=gs://...` 뒤에 실제 CSV 파일 경로를 지정합니다. 이렇게 하면 Cloud Storage의 CSV를 참조하는 외부 테이블이 생성됩니다.

10. SQL 쿼리 실행

외부 테이블이 준비되면 BigQuery에서 쿼리를 수행해 볼 수 있습니다. 집계 예제를 들어보겠습니다.

11. **콘솔**: BigQuery UI에서 상단 **쿼리 작성(Compose new query)** 창을 열고 SQL 문을 입력한 뒤 실행합니다. 예를 들어, 전체 운석 수를 구하려면:

```
SELECT COUNT(*) AS total_meteorites
FROM `프로젝트ID.meteorite_dataset.meteorites_ext`;
```

실행 결과 `total_meteorites = 34513` 과 같이 NASA 데이터와 일치함을 확인할 수 있습니다 ⁴.

12. **클라우드 CLI (bq)**: `bq query` 명령어로 같은 쿼리를 실행할 수 있습니다. 예:

```
bq query --nouse_legacy_sql 'SELECT COUNT(*) AS total_meteorites FROM
`[PROJECT_ID].meteorite_dataset.meteorites_ext`'
```

결과를 보면 전체 행수가 34,513임을 알 수 있습니다.

13. **추가 집계 예시**: 다양한 SQL 집계 함수를 사용하여 데이터를 분석합니다. 예를 들어 `fell_found` 별 개수를 확인하려면:

```
SELECT fell_found, COUNT(*) AS count
FROM `프로젝트ID.meteorite_dataset.meteorites_ext`
GROUP BY fell_found;
```

특정 `type_of_meteorite` 상위 5개를 보려면:

```
SELECT type_of_meteorite, COUNT(*) AS cnt
FROM `프로젝트ID.meteorite_dataset.meteorites_ext`
WHERE type_of_meteorite != ""
GROUP BY type_of_meteorite
ORDER BY cnt DESC
LIMIT 5;
```

평균 무게 및 최대/최소 무게는 다음 쿼리로 구할 수 있습니다:

```
SELECT AVG(mass_g) AS avg_mass, MIN(mass_g) AS min_mass, MAX(mass_g) AS max_mass
FROM `프로젝트ID.meteorite_dataset.meteorites_ext`;
```

콘솔에서는 쿼리 결과를 UI에서 바로 확인할 수 있고, CLI에서는 터미널에 결과가 출력됩니다.

학습 요약

- **서버리스 분석(BigQuery)**: BigQuery는 리소스 할당 없이 자동으로 확장되는 완전관리형 서버리스 데이터 웨어하우스입니다. 사용자는 인프라 대신 데이터 분석에 집중할 수 있습니다 ¹.
- **외부 테이블**: 외부 테이블을 이용하면 Cloud Storage의 CSV 파일을 **조회만**(읽기 전용) 할 수 있습니다 ³. 데이터를 따로 로드하지 않아도 SQL로 바로 분석이 가능합니다. BigQuery는 GCS, Bigtable, Google Drive 등의 외부 저장소를 지원합니다 ².

- **콘솔과 CLI 활용:** GCP 콘솔과 `gcloud`/`bq` CLI를 모두 사용하여 동일한 작업을 수행할 수 있습니다. 콘솔은 GUI를 통해 직관적으로 진행 가능하며, CLI는 스크립트화하여 반복 자동화에 유용합니다. 두 방법을 모두 익혀두면 상황에 맞게 유연하게 활용할 수 있습니다.

이 실습을 통해 GCP의 **서버리스 데이터 분석** 개념과 **BigQuery 외부 테이블** 사용법을 익힐 수 있었습니다. 다운로드나 서버 관리 없이 클라우드에서 대규모 데이터를 분석하는 경험이 되었기를 바랍니다.

참고 자료: BigQuery 개요 ¹ ² , 외부 테이블 문서 ³ , NASA Meteorite Landings 데이터셋 설명 ⁴ .

¹ ² ⁵ BigQuery 개요 | Google Cloud

<https://cloud.google.com/bigquery/docs/introduction?hl=ko>

³ Introduction to external tables | BigQuery | Google Cloud

<https://cloud.google.com/bigquery/docs/external-tables>

⁴ Meteorite Landings - Dataset - NASA Open Data Portal

<https://data.nasa.gov/dataset/meteorite-landings>

⁶ ⁷ Create Cloud Storage external tables | BigQuery | Google Cloud

<https://cloud.google.com/bigquery/docs/external-data-cloud-storage>